


중간 발표



자연어 처리 | 미니프로젝트

논문 제목 생성기

Ab2Ti (Abstract to Title)

202204046 류동우
202204249 이민우

* Contents

1. 주제
2. T5 Model
3. Dynamic Context Gates
4. 실험 결과
5. 향후 계획 및 기대효과

* 주제

제목을 어떻게 지을까?

1. [arXiv:2504.05226](#) [pdf, other] [cs.CL](#)

Proposing TAGbank as a Corpus of Tree-Adjoining Grammar Derivations

Authors: [Jungyeul Park](#)

Abstract: ...of lexicalized grammars, particularly Tree-Adjoining Grammar (TAG), has significantly advanced our understanding of syntax and semantics in natural language processing (**NLP**). While existing syntactic resources like the Penn Treebank and Universal Dependencies offer extensive annotations for phrase-structure and dependency parsing, there is a lack of large-sc... [▽ More](#)

Submitted 7 April, 2025; originally announced April 2025.

2. [arXiv:2504.04385](#) [pdf] [cs.CL](#)

Pre-trained Language Models and Few-shot Learning for Medical Entity Extraction

Authors: [Xiaokai Wang](#), [Guiran Liu](#), [Binrong Zhu](#), [Jacky He](#), [Hongye Zheng](#), [Hanlu Zhang](#)

Abstract: ...research can integrate knowledge graphs and active learning strategies to improve the model's generalization and stability, providing a more effective solution for medical **NLP** research. Keywords- Natural Language Processing, medical named entity recognition, pre-trained language model, Few-shot Learning, information extraction, deep learning [▽ More](#)

Submitted 6 April, 2025; originally announced April 2025.

3. [arXiv:2504.04275](#) [pdf, other] [cs.CL](#)

negativas: a prototype for searching and classifying sentential negation in speech data

Authors: [Túlio Sousa de Gois](#), [Paloma Batista Cardoso](#)

Abstract: ...four stages: i) analyzing a dataset of 22 interviews from the Falares Sergipanos database, annotated by three linguists, ii) creating a code using natural language processing (**NLP**) techniques, iii) running the tool, iv) evaluating accuracy. Inter-annotator consistency, measured using Fleiss' Kappa, was moderate (0.57). The tool identified 3,338 instances... [▽ More](#)

Submitted 5 April, 2025; originally announced April 2025.



* 제목 생성

Abstract

We introduce Clinical ModernBERT, a transformer-based encoder pretrained on large-scale biomedical literature, clinical notes, and medical ontologies, incorporating PubMed abstracts, MIMIC-IV clinical data, and medical codes with their textual descriptions. Building on ModernBERT [Warner et al., 2024]—the current state-of-the-art natural language text encoder featuring architectural upgrades such as rotary positional embeddings (RoPE), Flash Attention, and extended context length up to 8,192 tokens—our model adapts these innovations specifically for biomedical and clinical domains. Clinical ModernBERT excels at producing semantically rich representations tailored for long-context tasks. We validate this both by analyzing its pretrained weights and through empirical evaluation on a comprehensive suite of clinical NLP benchmarks.



Clinical ModernBERT: An efficient and long context encoder for biomedical text

Abstract

title

* 연구 목표

T5 모델을 기반으로 논문 초록으로부터
적절한 제목을 생성하는 파이프라인 구축.

"Dynamic Context Gate" 메커니즘을 도입하여
T5 모델의 제목 생성 성능 개선 가능성 탐색.


* T5 도입의 이유

1. 완전한 Text-to-Text Framework

T5는 입력과 출력을 모두 “텍스트”로 통일한 Seq2Seq 모델
-> “요약: 초록 → 제목 생성”과 같은 파이프라인을
한 번에 다룰 수 있어, 기본 구성요소
(임베딩→셀프어텐션→피드포워드→디코더)를 모두 구성 가능.

2. 사전학습(Transfer Learning)의 이점

논문 초록-제목 데이터는 보통 수십만 건 이상 필요하지만,
T5-base는 이미 C4 코퍼스 같은 방대한 데이터로 학습되어 있어,
적은 데이터로도 빠르게 수렴하고 안정적인 결과를 얻을 수 있음.



* 초기 문제점

T5-small 기본 모델 학습 시,
생성된 제목이 대부분 "True" 또는
유사한 단일 값으로 출력됨.
실제 제목과의 코사인 유사도 매우 낮음
(평균 0.05 수준).

```
초록 (일부): Recent options for Project Schedules (ROPS) has three recursive  
sampling/optimization shells. An outer Adaptive Simulated Annealing (ASA)  
optimization shell optimizes parameters of strategic Plans con...
```

실제 제목: Real Options for Project Schedules (ROPS)

생성된 제목: True

코사인 유사도: 0.1137

[샘플 17/17]

```
초록 (일부): Recent investigations have established an analogy between the entropy of  
four-dimensional supersymmetric black holes in string theory and entanglement  
in quantum information theory. Examples include...
```

실제 제목: E_6 and the bipartite entanglement of three qutrits

생성된 제목: False

코사인 유사도: -0.0252

--- 최종 결과 ---

평가된 테스트 샘플 17개에 대한 평균 코사인 유사도: 0.0522

--- 단일 입력 테스트 ---

입력 초록: The field of artificial intelligence has seen rapid progress, particularly in deep lea

생성된 제목: True

스크립트 실행 완료.

(t5-arxiv-title-generator-py3.11) (base) minu@minuui-MacBookPro text-to-text-transfer-transfor

* Dynamic Context Gates 구체화(1/2)

동적 게이트 계산

디코더가 t 번째 단어를 생성할 때,
인코더 컨텍스트 c (shape: $[d]$)
디코더 현 히든 h_t (shape: $[d]$)
이 둘을 연결(concat)

$$gate = \text{sigmoid}([c; h_t] \cdot W + b)$$

동적 컨텍스트 생성

계산된 gate 값을 이용해 두 벡터를 가중합.
이렇게 만들어진 c'_t 를 feed-forward나
attention 입력으로 사용하면,
디코더는 “지금 이 순간” 가장 필요한 정보만
강조하여 제목 단어를 뽑아낼 수 있음

$$c'_t = gate * c + (1 - gate) * h_t$$

* Dynamic Context Gates 구체화(2/2)

- 기존 연구와의 차별점
- 적용 도메인: 기계 번역, 일반 문서 요약이 아닌 "논문 초록 → 제목 생성" 태스크에 특화.
- 게이트 적용 위치: T5의 각 Transformer 블록(T5Block) 내부에 적용하여, 셀프 어텐션의 출력과 블록 입력(또는 디코더 은닉 상태) 간의 정보를 벡터 단위로 동적 조절.
- 구현 용이성: PyTorch 기반 서브클래싱으로 T5Block의 forward() 메소드만 수정하여 기존 Trainer 재사용 가능.

```
•  
Pseudo-code for T5Block forward with Dynamic Gate  
current_hidden_states = input_hidden_states  
current_hidden_states = self_attention_output  
  
gate_input = torch.cat((prev_hidden_states, current_hidden_states), dim=-1)  
gate_values = torch.sigmoid(self.dynamic_gate_linear(gate_input)) # nn.Linear  
gated_output = gate_values * prev_hidden_states + \\  
               (1 - gate_values) * current_hidden_states  
current_hidden_states = gated_output # To next layer/cross-attention
```

* 실험 설정

데이터셋: arXiv Dataset (Cornell-University/arxiv)

로컬 파일 경로: `"/Users/minu/Desktop/4-1/NLP1/arxiv_data/arxiv-metadata-oai-snapshot.json"`

샘플 수 (코드 설정 기준):

`NUM_TRAIN_SAMPLES = 1000`

`NUM_EVAL_SAMPLES = 200`

`NUM_TEST_SAMPLES = 200`

실제 테스트 시 사용된 샘플 수 (터미널 로그 기준): 140개 ([샘플 140/140])

모델: t5-small (Hugging Face Transformers)

주요 학습 파라미터 (train.py 코드 설정 기준):

`PREFIX = "generate title: "`

`MAX_INPUT_LENGTH = 512`

`MAX_TARGET_LENGTH = 64`

`OUTPUT_DIR = "./t5_arxiv_title_generator_local_poetry_v2"`

`TRAIN_MODEL = True` (학습 수행)

`learning_rate=3e-5`

`num_train_epochs=3`

`per_device_train_batch_size` 및 `gradient_accumulation_steps`는 장치(mps, cuda, cpu)에 따라 동적 조정.

`optim="adafactor"` (t5 모델의 경우)

평가 지표:

ROUGE Score (학습 중 `compute_metrics` 함수 내 사용)

코사인 유사도 (테스트 단계, Sentence Transformers `all-MiniLM-L6-v2` 임베딩 기반)

실행 환경: macOS (MPS 확인됨: 터미널 로그 사용 장치: mps), Poetry 가상환경

* 실험 결과 및 분석

학습 진행:

t5-small 모델을 사용하여

3 Epoch 학습 수행

학습 과정에서 ROUGE 점수를 통해 검증
(구체적인 ROUGE 점수 로그는 없으나
compute_metrics 함수에서 계산).

to a conserved scalar density. In the random...

실제 제목 : Model C critical dynamics of random anisotropy magnets

생성된 제목 : The structural disorder of random anisotropy magnets with the non-conserved n-component order parameter and scalar density

코사인 유사도 : 0.6713

[샘플 83/140]

초록 (일부) : We re-discuss the evolutionary state of upper main sequence magnetic stars

using a sample of Ap and Bp stars with accurate Hipparcos parallaxes and

definitely determined longitudinal magnetic fields...

실제 제목 : Evolution of Magnetic Fields in Stars Across the Upper Main Sequence:

II. Observed distribution of the magnetic field geometry

생성된 제목 : The evolution of the obliquity angle beta in upper main sequence magnetic stars

코사인 유사도 : 0.7925

[샘플 84/140]

초록 (일부) : The usual procedure of including a finite number of vertices in Non

Perturbative Renormalization Group equations in order to obtain n -point

correlation functions at finite momenta is analyzed. Thi...

실제 제목 : Correlation functions in the Non Perturbative Renormalization Group and

field expansion

* 실험 결과 및 분석

생성 결과 및 코사인 유사도 평가
(테스트 데이터셋 - 140개 샘플):
평균 코사인 유사도: 0.5679

"True" 또는 "False" 포함 문제:
단일 입력 테스트 결과: "False-to-
Sequence tasks"

일부 샘플(예: 샘플 88, 89, 105, 107,
111, 136)에서 생성된 제목에
"True"가 포함되는 경향 관찰.

->모델이 특정 패턴에 과적합되었거나,
여전히 의미 있는 제목 생성에 어려움을
겪었음

```
ture 441 (2006),  
486), that an analogue of the X-ray magnetic circular dichroism (XMCD)  
experiment can be performed with the transmission elec...  
실제 제목: First principles theory of chiral dichroism in electron micr  
oscopy  
applied to 3d ferromagnets  
생성된 제목: An analogue of the X-ray magnetic circular dichroism (XMCD  
) experiment with the transmission electron microscope  
코사인 유사도: 0.6085
```

```
--- 최종 결과 ---  
평가된 테스트 샘플 140개에 대한 평균 코사인 유사도: 0.5679
```

```
--- 단일 입력 테스트 ---  
입력 초록: The field of artificial intelligence has seen rapid progress  
, particularly in deep learning. This study focuses on novel architectu  
res for sequence-to-sequence tasks, aiming to improve efficiency and pe  
rformance on abstractive summarization benchmarks. We also investigate  
the ethical implications of large-scale language model deployment.  
생성된 제목: False-to-Sequence tasks
```

```
스크립트 실행 완료.  
(t5-arxiv-title-generator-py3.11) (base) minu@minuui-MacBookPro text-to  
-text-transfer-transformer %
```

⌘K to generate a command

* 향후 연구 계획, 기대효과

only T5

학습량, 샘플 늘리고 테스트

subclassed T5 + Dynamic Context Gates

학습량, 샘플 늘고 테스트

Beam search 외
Top-k/Top-p sampling 등
비교를 통한 디코딩 전략

Cosine 유사도 이외의 evaluation method 추가,
실제 output 추론적 분석, 정성적 평가 방법 고려

기대효과

"Dynamic Context Gate"를 통해 초록의 핵심 정보를 보다
효과적으로 반영하여, 의미론적으로 풍부하고 정확한 제목 생성
전반적인 ROUGE 점수 및 코사인 유사도 향상

감사합니다.

